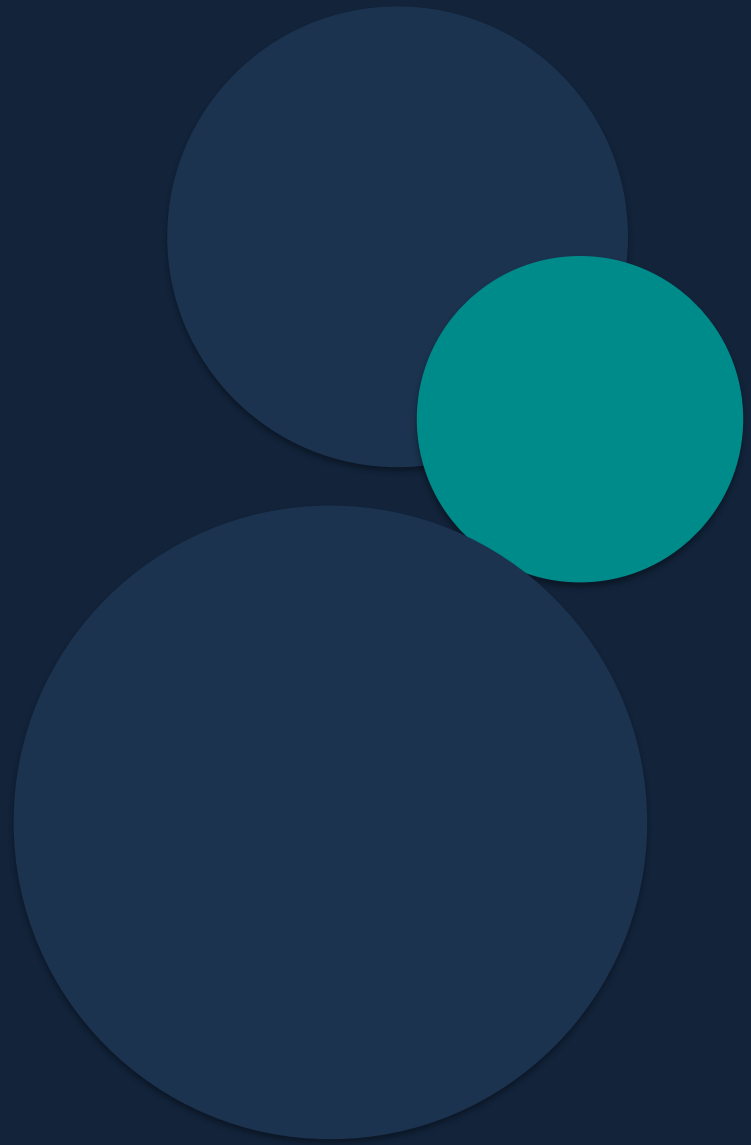
# Asistente normativo

Prototipo del cote 2

Sebastián Cruz Cardona · Institución Universitaria EAM

Código 240220222010



# ¿Qué problema aborda?

La meta no es reemplazar el criterio jurídico, sino ayudar a localizar información y controlar el alcance de la respuesta.

## Problema

Una respuesta generada puede sonar convincente aunque no recupere el fragmento que realmente responde la pregunta.

## Usuarios previstos

Abogados y personal de apoyo de un juzgado en Colombia que necesitan explorar información normativa o consultar datos de ejemplo.

## Objetivo del corte 2

Integrar clasificación de solicitudes con búsqueda documental, respuesta con citas y evaluación comparativa de recuperación.

## Qué puede hacer el prototipo

Buscar fragmentos en un corpus, generar una respuesta trazable y reconocer cuándo faltan datos o evidencia.

## Qué no pretende hacer

No consulta expedientes reales, no modifica procesos y no ofrece una decisión jurídica definitiva.

# Términos clave, en lenguaje sencillo

Estos términos explican cómo pasa el sistema de una pregunta a una respuesta apoyada por documentos.

### RAG

Generación aumentada por recuperación: primero busca evidencia; después redacta con el material recuperado.

### Embedding

Representación numérica del texto que ayuda a encontrar fragmentos con significado parecido.

### Búsqueda semántica

Busca por similitud de significado, aunque no coincidan todas las palabras.

### BM25

Búsqueda léxica: prioriza coincidencias de palabras entre pregunta y documentos.

### RRF

Fusiona las posiciones de dos rankings para combinar búsqueda semántica y léxica.

### Reranking

Vuelve a ordenar los candidatos según su relevancia para la pregunta; añade coste de procesamiento.

**Importante: similitud o puntuación alta no equivale a certeza ni demuestra que una respuesta sea correcta.**

# ¿Qué documentos consulta?

La demostración trabaja con dos documentos Markdown creados dentro de la sesión de Colab.

### constitucion_politica.md

Texto de la Constitución Política de Colombia con artículos y secciones. En el caso mostrado, el artículo 4 contiene la regla de prevalencia constitucional.

### guia_uso.md

Guía de uso del asistente: describe cómo formular consultas y que la consulta de procesos es de solo lectura y usa códigos ficticios.

**Preparación del corpus**

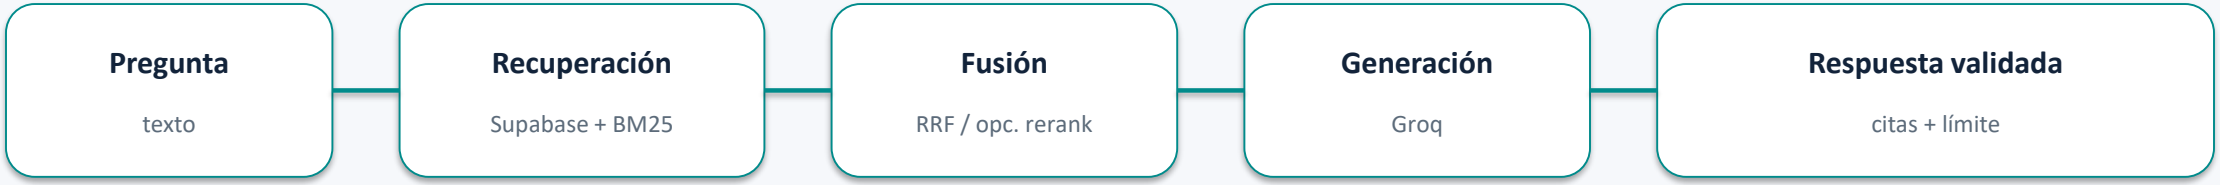
Limpieza → fragmentación por secciones/ventanas → embeddings → índice → fragmentos y vectores en Supabase.

Cada fragmento conserva metadatos de fuente, sección y versión para facilitar su trazabilidad.

# Esquema del sistema

El prototipo contiene dos recorridos: búsqueda documental (RAG) y clasificación con herramienta de consulta ficticia.

## RECORRIDO RAG DOCUMENTAL




## RECORRIDO DE CLASIFICACIÓN Y HERRAMIENTAS




### Servicios y controles

Supabase almacena/busca fragmentos; Groq genera; Pydantic valida estructura. Las credenciales se guardan en secretos de Colab y no se envían al modelo.

# Caso completo: pregunta → respuesta → fuente

Pregunta de prueba registrada en el notebook; respuesta producida con la estrategia híbrida B (RRF).

PREGUNTA

**Si una ley contradice la Constitución, ¿cuál debe prevalecer?**

RESPUESTA DEL PROTOTIPO · estado: respondida

"En caso de contradicción entre la Constitución y una ley, la Constitución prevalece, ya que es la norma suprema y se aplica en todo caso de incompatibilidad entre la Constitución y la ley u otra norma jurídica."

La respuesta incluyó la referencia [F1].

FUENTE [F1]

**Constitución Política de Colombia · Artículo 4**

"La Constitución es norma de normas. En todo caso de incompatibilidad entre la Constitución y la ley u otra norma jurídica, se aplicarán las disposiciones constitucionales."

## Qué demuestra

La fuente respalda la idea principal.

## Qué no demuestra

No garantiza exactitud en todos los casos.

## Verificación humana

Se contrastó la respuesta con el artículo.

# Resultados de evaluación de recuperación

Cuatro preguntas de desarrollo con unidades de evidencia anotadas; cero fallos técnicos en esas ejecuciones.

| Estrategia | Precisión@3 | Recall@3 | MRR | Cobertura |
|---|---|---|---|---|
| **A · Semántica** | 0,250 | 0,625 | 0,625 | 0,625 |
| **B · Híbrida + RRF** | 0,417 | 1,000 | 1,000 | 1,000 |
| **C · Híbrida + rerank** | 0,417 | 1,000 | 1,000 | 1,000 |

### Cómo leerlo

Recall@3 = proporción de fragmentos relevantes recuperados entre los tres primeros. MRR = qué tan arriba aparece el primer resultado relevante. Cobertura = si el contexto contiene las unidades de evidencia anotadas.

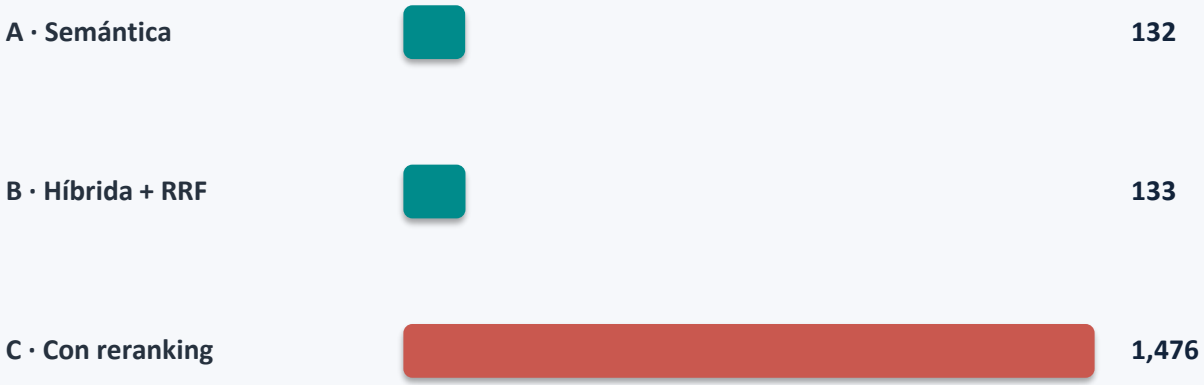
### Resultado principal

B y C recuperaron toda la evidencia anotada en los cuatro casos. B lo logró sin el coste alto del reranker.

# Decisión técnica: elegir B (híbrida con RRF)

La opción elegida equilibra recuperación de evidencia, simplicidad y tiempo de ejecución.

**Latencia mediana de recuperación (ms)**




## Decisión

B combina búsqueda semántica y BM25 con Reciprocal Rank Fusion (RRF).

En los 4 casos anotados, B y C obtuvieron las mismas métricas promedio.

La mediana de C fue ~11,1 veces la de B en recuperación.

**Por eso, el reranking no se justifica en esta muestra.**

**Interpretación**

No significa que reranking nunca ayude; significa que en esta prueba no añadió una mejora medible que compense su coste.

# Fallo observado: la búsqueda semántica no bastó

El mismo caso permite mostrar por qué no basta con que el modelo redacte de forma prudente.

ESTRATEGIA A · SOLO SEMÁNTICA

**Estado: evidencia_insuficiente**

“No se dispone de evidencia documental que establezca la relación de prevalencia entre una ley y la Constitución…”

**Revisión manual: la respuesta no contesta la pregunta; la cita no respalda la afirmación.**

ESTRATEGIA B · HÍBRIDA + RRF

**Estado: respondida**

Recuperó el artículo 4 y respondió que la Constitución prevalece, con cita [F1].

**Revisión manual: correcta, fiel al fragmento y con cita que respalda la afirmación.**

### Qué falló

El contexto seleccionado por A no entregó la evidencia útil a la generación.

### Cómo se detectó

Comparación con el artículo 4 y revisión humana; no solo validación del JSON.

### Qué aporta el control

La validación de citas puede rechazar salidas mal formadas, pero no prueba por sí sola la fidelidad semántica.

# Límites y uso responsable

El prototipo es una prueba técnica controlada, no una herramienta lista para operar en un juzgado.

### Corpus reducido

Dos documentos didácticos; no cubre la legislación ni la jurisprudencia necesaria para consultas generales.

### Evaluación limitada

Cuatro preguntas con evidencia anotada. Las métricas no son una garantía de exactitud jurídica.

### Revisión humana

Hay que comprobar que cada afirmación esté respaldada por el pasaje citado.

### Datos ficticios

Las consultas de procesos operan sobre registros locales de demostración, no expedientes reales.

### Privacidad

Las credenciales van en secretos de Colab; revisar trazas y evidencias antes de compartir.

### Documentos nuevos

Convertir un PDF/Word/Excel a Markdown no lo incorpora al RAG: requiere ingestión, embeddings y carga.

**Regla práctica: si la evidencia no aparece o no respalda la respuesta, el sistema debe pedir aclaración o reconocer la insuficiencia.**

# Aprendizajes

### 1 · Recuperar mejor

Combinar señales semánticas y léxicas mejoró la cobertura en la muestra.

### 2 · Medir antes de añadir

El reranker elevó el tiempo sin mejorar las métricas observadas.

### 3 · Citar no basta

La respuesta debe contrastarse con la fuente; el formato válido no asegura fidelidad.